Assignment 1: MapReduce

รายงานสรุปแนวคิดและตัวอย่างการประยุกต์ใช้งาน MapReduce

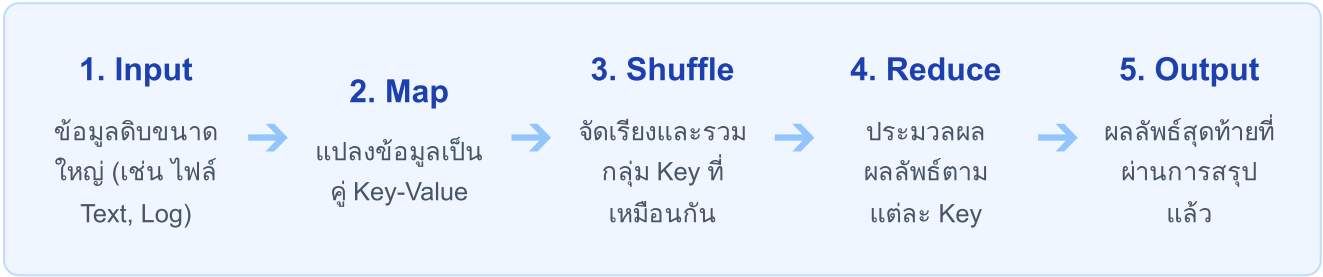
1. MapReduce คืออะไร?

MapReduce คือ รูปแบบการเขียนโปรแกรม (Programming Model) และสถาปัตยกรรมการประมวลผลข้อมูลที่ออกแบบมาเพื่อจัดการและประมวลผลชุดข้อมูลขนาดใหญ่ (Big Data) แบบคู่ขนาน (Parallel Processing) บนกลุ่มเครื่องคอมพิวเตอร์แบบกระจายศูนย์ (Distributed Cluster) แนวคิดนี้ถูกนำเสนอครั้งแรกโดย Google เพื่อแก้ปัญหาการประมวลผลข้อมูลมหาศาลอย่างมีประสิทธิภาพและทนทานต่อความล้มเหลว (Fault-tolerant)

การทำงานของ MapReduce แบ่งออกเป็น 2 ขั้นตอนหลัก (ฟังก์ชัน) ได้แก่:

- **Map (การกระจายข้อมูล):** รับข้อมูลอินพุตเข้ามา แล้วทำการแบ่งหรือแปลงข้อมูลเหล่านั้นให้อยู่ในรูปแบบของ *Key-Value Pairs (คู่ของคีย์และค่า)* โดยกระบวนการนี้จะเกิดขึ้นพร้อมๆ กันในหลายๆ โหนด (Node) ในคลัสเตอร์
- **Reduce (การรวมข้อมูล):** รับผลลัพธ์ที่เป็น Key-Value Pairs จากฟังก์ชัน Map มารวบรวม ประมวลผล หรือสรุปผล (Aggregation) ตาม Key ที่เหมือนกัน เพื่อให้ออกมาเป็นผลลัพธ์สุดท้ายที่เล็กลงและตรงตามความต้องการ

ระหว่างขั้นตอน Map และ Reduce จะมีกระบวนการที่เรียกว่า **Shuffle & Sort** ซ่อนอยู่ ซึ่งทำหน้าที่จัดเรียงและจัดกลุ่มข้อมูลที่มี Key เดียวกันเข้าด้วยกัน ก่อนจะส่งต่อให้ฟังก์ชัน Reduce ประมวลผล ข้อดีที่สำคัญที่สุดของ MapReduce คือความสามารถในการขยายระบบ (Scalability) ได้อย่างง่ายดายเพียงแค่เพิ่มจำนวนเครื่องเซิร์ฟเวอร์



2. ตัวอย่าง Use-case การใช้งาน MapReduce

เนื่องจาก MapReduce มีความโดดเด่นในการจัดการข้อมูลมหาศาล (Terabytes หรือ Petabytes) จึงถูกนำไปประยุกต์ใช้ในอุตสาหกรรมและงานด้าน Data Science หลากหลายรูปแบบ ดังตัวอย่างต่อไปนี้:

1. การนับจำนวนคำ (Word Count)

นี่คือตัวอย่างคลาสสิกที่สุดของ MapReduce ใช้สำหรับวิเคราะห์ความถี่ของคำในคลังเอกสารขนาดใหญ่ (เช่น บทความใน Wikipedia ทั้งหมด) ฟังก์ชัน Map จะสกัดคำแต่ละคำออกมาและให้ค่าเป็น 1 (คำ, 1) จากนั้นฟังก์ชัน Reduce จะรวมค่าของคำที่เหมือนกันเข้าด้วยกันเพื่อหาผลรวมว่าแต่ละคำปรากฏกี่ครั้ง

2. การทำดัชนีสำหรับ Search Engine

เครื่องมือค้นหาอย่าง Google หรือ Yahoo ใช้ MapReduce เพื่อสร้าง Inverted Index (ดัชนีระบุตำแหน่งคำ) โดยระบบจะค้นหาว่าคำๆ หนึ่ง (Key) ปรากฏอยู่ในเอกสารหรือเว็บไซต์ใดบ้าง (Value) เพื่อให้เมื่อผู้ใช้พิมพ์คำค้นหา ระบบสามารถดึงรายชื่อเว็บไซต์ที่เกี่ยวข้องขึ้นมาแสดงได้อย่างรวดเร็ว

3. การวิเคราะห์ Log File ของเซิร์ฟเวอร์

เว็บไซต์ขนาดใหญ่มี Log ของผู้ใช้งานนับล้านบรรทัดต่อวัน MapReduce สามารถใช้วิเคราะห์ Log เหล่านี้เพื่อหาข้อมูลเชิงลึก เช่น "หน้าเว็บใดถูกเข้าชมมากที่สุด", "IP Address ใดพยายามโจมตีระบบ" หรือสรุปสถิติปริมาณการใช้แบนด์วิดท์ในแต่ละช่วงเวลา

4. ระบบแนะนำสินค้า (Recommendation System)

แพลตฟอร์มอีคอมเมิร์ซใช้ MapReduce ประมวลผลประวัติการซื้อของลูกค้าทุกคนเพื่อหารูปแบบความสัมพันธ์ (เช่น ผู้ที่ซื้อสินค้า A มักจะซื้อสินค้า B ด้วย) โดย Map จะจับคู่สินค้าที่ถูกซื้อในบิลเดียวกัน และ Reduce จะนับความถี่ของคู่สินค้านั้นเพื่อสร้างเป็นกฎในการแนะนำสินค้าในอนาคต

สรุป: แม้ในปัจจุบันจะมีเทคโนโลยีใหม่ๆ เช่น Apache Spark ที่ทำงานได้รวดเร็วกว่าด้วยการประมวลผลในหน่วยความจำ (In-memory) แต่สถาปัตยกรรมแนวคิดของ MapReduce ก็ยังคงเป็นรากฐานสำคัญและเป็นจุดเริ่มต้นของการประมวลผล Big Data และยังคงถูกใช้งานอยู่ในระบบ Hadoop (HDFS) สำหรับงาน Batch Processing ที่ต้องการความเสถียรสูงและจัดการข้อมูลขนาดใหญ่โดยไม่สิ้นเปลืองทรัพยากรหน่วยความจำ