Assignment 2

สรุปเนื้อหา Apache Hive

Data Engineering / Big Data

1. Apache Hive คืออะไร?

Apache Hive คือระบบคลังข้อมูล (Data Warehouse Software Project) ที่ถูกสร้างขึ้นมาเพื่อทำงานบนระบบนิเวศของ Apache Hadoop หน้าที่หลักของ Hive คือการอำนวยความสะดวกในการอ่าน เขียน และจัดการชุดข้อมูลขนาดใหญ่ (Large Datasets) ที่ถูกจัดเก็บแบบกระจายตัว (Distributed Storage) เช่น ใน Hadoop Distributed File System (HDFS) หรือระบบจัดเก็บข้อมูลอื่นๆ เช่น Amazon S3

> **จุดเด่นสำคัญ: ภาษา HiveQL (HQL)**
>
> ในยุคแรกเริ่ม การประมวลผลข้อมูลบน Hadoop จำเป็นต้องเขียนโปรแกรมด้วยภาษา Java ผ่านกรอบการทำงาน MapReduce ซึ่งมีความซับซ้อน Hive จึงเข้ามาแก้ปัญหานี้โดยสร้างส่วนติดต่อผู้ใช้ที่ใช้ภาษา **HiveQL (HQL)** ซึ่งมีโครงสร้างและคำสั่งคล้ายคลึงกับ SQL ทำให้ผู้ที่มีความคุ้นเคยกับฐานข้อมูลเชิงสัมพันธ์ (Relational Database) สามารถคิวรี (Query) และวิเคราะห์ข้อมูลระดับ Big Data ได้อย่างรวดเร็ว โดยไม่ต้องเขียนโค้ดที่ซับซ้อน

ข้อควรทราบ: Hive ถูกออกแบบมาเพื่อการวิเคราะห์ข้อมูลแบบแบทช์ (OLAP - Online Analytical Processing) และการจัดการคลังข้อมูล ไม่เหมาะสำหรับการทำธุรกรรมแบบเรียลไทม์ (OLTP - Online Transaction Processing) เนื่องจากมี Latency ในการประมวลผลสูงกว่าฐานข้อมูลปกติ

2. Apache Hive มีการทำงานอย่างไร?

สถาปัตยกรรมของ Hive ทำหน้าที่เป็นตัวกลางในการแปลงคำสั่ง SQL-like ให้กลายเป็นกระบวนการทำงาน (Jobs) ที่สามารถประมวลผลได้จริงบนคลัสเตอร์ของ Hadoop (เช่น แปลงเป็น MapReduce, Tez หรือ Spark) โดยมีองค์ประกอบและขั้นตอนการทำงานหลักดังนี้:

STEP 1: USER INTERFACE

Client / UI

ผู้ใช้งานส่งคำสั่ง (Query) ผ่านช่องทางต่างๆ เช่น Command Line Interface (CLI), Web UI หรือแอปพลิเคชันภายนอกที่เชื่อมต่อผ่าน JDBC/ODBC

STEP 2: PROCESSING COORDINATOR

Driver

รับคำสั่งจาก UI เพื่อเริ่มต้น Session การทำงาน โดย Driver จะทำหน้าที่ประสานงานระหว่างส่วนต่างๆ ติดตามสถานะวงจรชีวิตของ Query และส่งต่อผลลัพธ์กลับไปยังผู้ใช้

STEP 3: QUERY TRANSLATION

Compiler & Optimizer

STEP 4: JOB EXECUTION

Execution Engine